

« CONSTRUIRE UN PIPELINE DE TRAITEMENT DE DONNÉES »

Objectif

Le projet suit une démarche **ETL** : extraction, transformation et chargement des données.

Réaliser un petit pipeline de données permettant de :

- lire des données depuis un fichier CSV ;
- contrôler et nettoyer les données ;
- effectuer des traitements avec Pandas et NumPy ;
- produire des indicateurs et des graphiques ;
- enregistrer les données nettoyées dans une base de données.

Pipeline à réaliser

```
CSV
↓
Python / Pandas
↓
Contrôle et nettoyage
↓
Transformation / Analyse
↓
Graphiques
↓
Base de données
```

Contexte

Une entreprise souhaite analyser des données de déplacements urbains.

Les données sont fournies dans le fichier : `mobilité.csv`

Le fichier contient les colonnes suivantes :

```
id
date_trajet
station_depart
station_arrivee
duree
distance
transport
```

Certaines données peuvent contenir des anomalies. Votre programme devra donc effectuer un contrôle avant d'utiliser les données.

Travail demandé

1. Importer les données

Lire le fichier CSV avec Pandas.

Afficher :

- les premières lignes ;
- le nombre de lignes et de colonnes ;
- les noms des colonnes ;
- les types de données.

2. Contrôler la qualité des données

Rechercher :

- les valeurs manquantes ;
- les doublons ;
- les valeurs incohérentes.

Identifier les lignes problématiques.

3. Nettoyer les données

Corriger ou supprimer les données incorrectes.

Exemples :

- supprimer les doublons ;
- traiter les durées manquantes ;
- supprimer une durée négative ;
- convertir les colonnes numériques ;
- convertir `date_trajet` au format `date`.

Le DataFrame final devra contenir uniquement des données exploitables.

4. Effectuer les traitements

Calculer au minimum :

- le nombre total de trajets ;
- la distance totale parcourue ;
- la durée moyenne des trajets ;
- la durée minimale ;
- la durée maximale ;
- le moyen de transport le plus utilisé ;

- la station de départ la plus utilisée ;
- le trajet le plus fréquent.

Utiliser **NumPy** pour réaliser au moins un calcul statistique.

5. Réaliser des graphiques

Avec Matplotlib, créer au minimum **deux graphiques**.

Exemples :

- nombre de trajets par moyen de transport ;
- distance totale par moyen de transport ;
- nombre de trajets par station de départ.

Les graphiques doivent comporter :

- un titre ;
- des axes correctement nommés ;
- une légende si nécessaire.

6. Exporter les résultats

Créer un fichier : **resultats.csv**

Il devra contenir les données nettoyées ou les résultats d'analyse.

7. Charger les données dans une base de données

Créer une table dans une base de données relationnelle.

Exemple :

```
CREATE TABLE trajets (  
    id INT PRIMARY KEY,  
    date_trajet DATE,  
    station_depart VARCHAR(50),  
    station_arrivee VARCHAR(50),  
    duree INT,  
    distance DECIMAL(6,2),  
    transport VARCHAR(30)  
);
```

Le programme Python devra ensuite charger les données nettoyées dans cette table.

Organisation du projet

Organiser le projet de manière claire :

```
projet_pipeline_data /  
├── mobilite.csv  
├── traitement.py  
├── analyse.py  
├── graphiques.py  
├── chargement_bdd.py  
└── main.py
```

Le fichier `main.py` devra permettre d'exécuter le traitement complet.

BONUS

Les étudiants qui terminent le projet peuvent améliorer le pipeline.

Bonus 1 — MongoDB

Exporter les données nettoyées au format JSON et les charger dans MongoDB.

CSV → Pandas → nettoyage → JSON → MongoDB

Bonus 2 — Flask

Créer une petite interface Web permettant d'afficher :

- les indicateurs ;
- les graphiques ;
- quelques données issues de la base.

Bonus 3 — PySpark

Reproduire une partie du traitement avec PySpark.

Bonus 4 — IA

Ajouter une fonctionnalité utilisant l'IA pour produire automatiquement un commentaire des résultats obtenus.

Exemple :

« Le vélo représente le moyen de transport le plus utilisé. La distance moyenne parcourue est de... »

Bonus 5 — Amélioration du pipeline

Permettre à l'utilisateur de choisir le fichier CSV à traiter.

```
Choisir un fichier
↓
Lecture
↓
Nettoyage
↓
Analyse
↓
Graphiques
↓
Base de données
```